Arquitetura do Sistema Preditivo Multiagente

CardioIA · Fase 6 · Lucas Yuji Nakayama Hirano - RM 563420

O sistema recebe os dados de um paciente, calcula a probabilidade de pico de risco cardíaco com um modelo de Machine Learning (Random Forest) e usa agentes especializados, construidos com o OpenAI Agents SDK, para cruzar o resultado com a base de protocolos e gerar uma recomendação final estruturada. O LLM usado nos agentes foi openai/gpt-oss-120b, acessado pela API compatível da Groq.

1. Diagrama da arquitetura

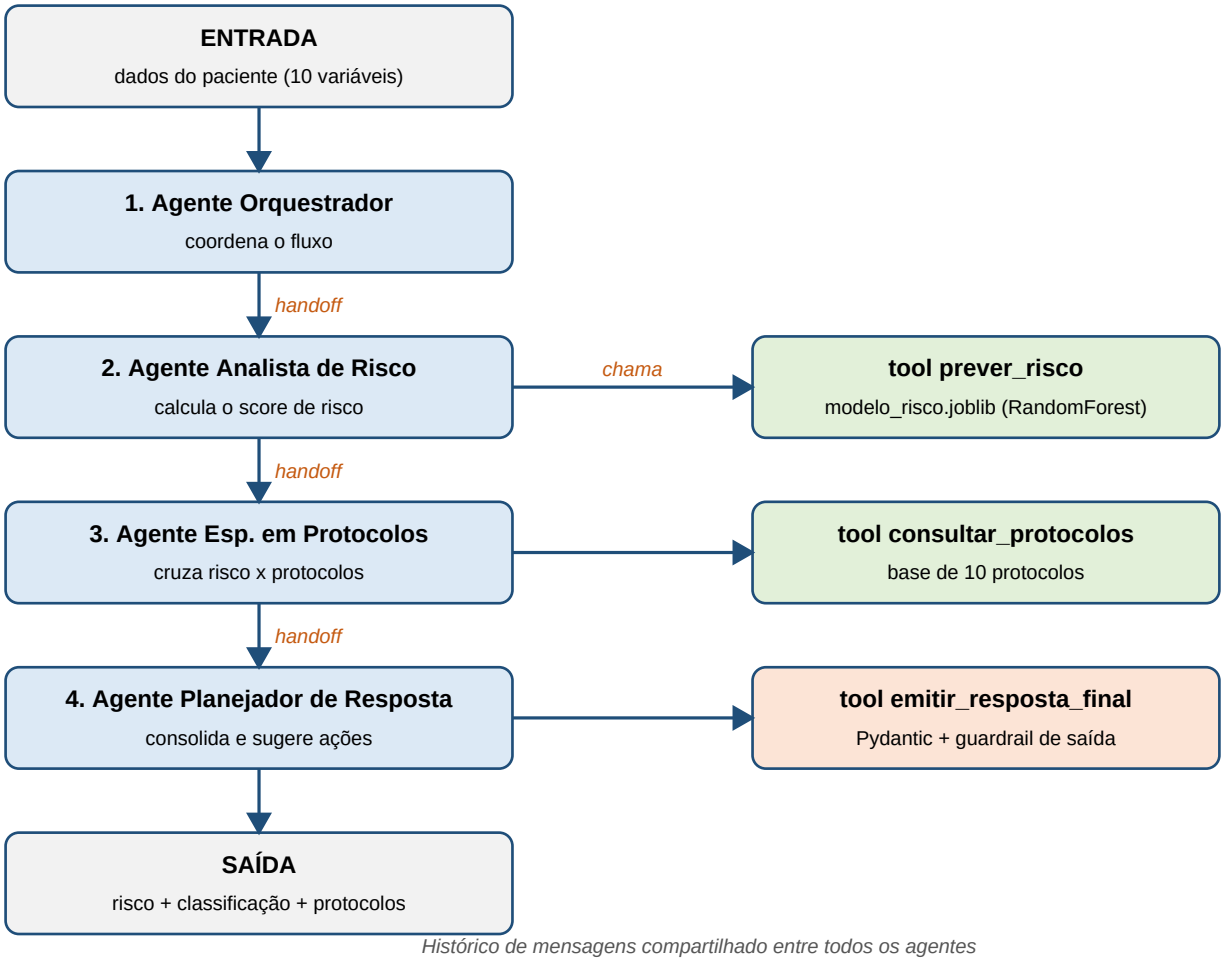

Histórico de mensagens compartilhado entre todos os agentes

2. Papel de cada agente

Agente	Papel	Tools	Handoff para
Orquestrador	Recebe os dados do paciente e coordena o fluxo entre os agentes, sem responder por conta própria.	-	Analista de Risco
Analista de Risco	Extrai as 10 variáveis clínicas, consulta o modelo de ML e obtem a probabilidade e a classificação (BAIXO, MODERADO, ALTO).	prever_risco	Esp. em Protocolos
Especialista em Protocolos	Consulta a base de protocolos e identifica quais são acionados pelos dados do paciente e pelo risco previsto.	consultar_protocolos	Planejador de Resposta
Planejador de Resposta	Consolida risco, classificação e protocolos e sugere ações operacionais priorizadas; emite a resposta estruturada.	emitir_resposta_final	- (agente final)

3. Handoffs, tools, histórico e validação

Recurso	Como foi implementado
Handoffs	Cada agente encaminha o caso ao próximo com handoff() do OpenAI Agents SDK; o encaminhamento recebe um campo 'motivo' (log [handoff]) que registra o fluxo.
Tools	prever_risco (carrega o modelo salvo com joblib e devolve a probabilidade), consultar_protocolos (aplica as regras da base) e emitir_resposta_final (gera a saída estruturada).
Histórico de mensagens	A conversa (dados do paciente, chamadas de tools e handoffs) é repassada de um agente ao outro; após o fluxo, o histórico é reutilizado em uma pergunta de acompanhamento.
Validação de saída	A resposta é validada com Pydantic (RespostaFinal) e por um guardrail que confere se a probabilidade está entre 0 e 1, se a classificação corresponde a probabilidade e se há protocolos em risco ALTO. Se falhar, o fluxo é repetido (até 3 tentativas).

4. Exemplo real de entrada e saída

Entrada (dados simulados do novo paciente):

```
novo_caso = {
  "idade_media": 62, "carga_sistema": 92, "tempo_espera": 75,
  "fc_media": 118, "spo2_media": 89, "pa_sistolica": 100,
  "temperatura": 37.5, "densidade_eventos": 7, "eventos_24h": 5,
  "disponibilidade_recursos": 25
}
```

Saída (resposta final do sistema, execução real):

```
RISCO PREVISTO: 0.96
CLASSIFICAÇÃO: ALTO

PROTOCOLOS SUGERIDOS:
- Se carga do sistema > 85% -> abrir unidades temporárias
- Se disponibilidade_recursos < 30% -> redistribuir insumos
- Se densidade_eventos > 6 -> ativar plano de contingência
- Se risco sistêmico alto -> ativar estado de emergência

AÇÕES OPERACIONAIS:
- Abrir unidades temporárias na ala de emergência para absorver a carga.
- Redistribuir insumos críticos entre unidades.
- Ativar o plano de contingência (densidade de eventos alta).
- Declarar estado de emergência para resposta coordenada.
```