Relatório Técnico – Modelo Preditivo de Pico de Risco

CardioIA · Fase 6 · Lucas Yuji Nakayama Hirano – 563420

1. Objetivo e dados

O objetivo do modelo é prever a variável binária `pico_risco` (0 = sem pico, 1 = pico de risco) a partir de 10 variáveis clínicas e operacionais: idade média, carga do sistema, tempo de espera, frequência cardíaca, SpO2, pressão sistólica, temperatura, densidade de eventos, eventos nas últimas 24 h e disponibilidade de recursos. Foi usada a base sintética de 5.000 registros fornecida no enunciado (`np.random.seed(42)`), o que permite trabalhar sem dados sensíveis. A classe positiva representa 26,6% dos casos (73,4% sem pico), um desbalanceamento moderado.

2. Algoritmo e justificativa

Foi escolhido o **Random Forest** (`RandomForestClassifier` , 200 árvores, `class_weight="balanced"`). A escolha se justifica porque: (i) o problema é de classificação supervisionada tabular; (ii) o alvo depende de limiares sobre as variáveis, e árvores de decisão representam bem esse tipo de regra; (iii) o modelo não exige normalização dos dados; (iv) fornece `predict_proba` , necessário para entregar a probabilidade de risco aos agentes; e (v) oferece importância de variáveis, o que facilita a interpretação.

3. Preparação e validação

As variáveis já estão em formato numérico e sem valores ausentes, então não foi necessária limpeza adicional. Os dados foram separados em **80% treino e 20% teste** (`train_test_split` , `random_state=42` , `stratify=y`), mantendo a proporção das classes nos dois conjuntos. Além disso, foi feita validação cruzada de 5 partes sobre toda a base. O modelo treinado foi salvo com `joblib` em `models/modelo_risco.joblib` e é carregado pelo Agente Analista de Risco por meio da tool `prever_risco` .

4. Resultados e interpretação das métricas

Métrica	Valor
Acurácia no teste (1.000 amostras)	99,90%
Acurácia média na validação cruzada (5 partes)	99,74%
Precisão / recall / F1 da classe "pico"	1,00 / 1,00 / 1,00 (arredondado)

A acurácia no teste e na validação cruzada são muito próximas, o que indica ausência de sobreajuste em relação a esta base. Como as classes são desbalanceadas, a acurácia sozinha poderia enganar; por isso também foram avaliados precisão, recall e F1 por classe, que confirmam o bom desempenho nas duas classes.

5. Análise da matriz de confusão

	Previsto: sem pico	Previsto: pico
Real: sem pico	734 (verdadeiros negativos)	0 (falsos positivos)
Real: pico	1 (falso negativo)	265 (verdadeiros positivos)

O modelo não gerou nenhum falso positivo e cometeu apenas um falso negativo (recall de 265/266 ≈ 99,6% para a classe de pico). Em um contexto de saúde, o falso negativo é o erro mais grave, pois deixa de alertar sobre um pico de risco; por isso esse é o indicador que mais deve ser acompanhado. As variáveis mais importantes foram `carga_sistema` (0,216), `disponibilidade_recursos` (0,213), `tempo_espera` (0,202) e `spo2_media` (0,173), seguidas de `fc_media` e `eventos_24h`. Idade, temperatura, pressão sistólica e densidade de eventos ficaram abaixo de 0,02.

6. Limitações

- **Alvo determinístico:** `pico_risco` foi construído por regras fixas sobre as próprias variáveis. As variáveis mais importantes coincidem com as usadas na regra, e as demais têm importância quase nula; ou seja, o modelo reaprendeu a regra. Por isso, a acurácia próxima de 100% reflete a base simulada e **não** deve ser interpretada como desempenho em dados reais.
- **Sem dados reais:** não há validação externa, ruído de medição, dados faltantes nem variação entre hospitais.

- **Limiares de classificação não validados:** BAIXO (< 0,4), MODERADO (0,4 a 0,7) e ALTO (≥ 0,7) foram definidos pela equipe, sem calibração clínica.
- **Escopo:** o modelo estima risco operacional e sistêmico em dados simulados; não faz diagnóstico nem substitui avaliação profissional.
- **LLM nos agentes:** o modelo de linguagem pode sugerir ações além dos protocolos retornados; a validação de saída reduz, mas não elimina, esse risco.

7. Melhorias propostas

Treinar com dados reais anonimizados ou com rótulos com ruído, para avaliar a generalização; comparar com Regressão Logística e Gradient Boosting; incluir curvas ROC e Precision-Recall; calibrar as probabilidades e ajustar o limiar priorizando a redução de falsos negativos; usar validação cruzada estratificada com busca de hiperparâmetros; restringir as ações dos agentes aos protocolos recuperados; e monitorar o desempenho do modelo ao longo do tempo (deriva dos dados).